

vectorjobs — Estado actual

Centroides, valor de mercado y costos de cómputo

Equipo vectorjobs

Pipeline de recomendación job $\leftrightarrow$ skill

18 de junio de 2026

Agenda

- 1 Contexto y estado actual
- 2 La idea de los centroides
- 3 Valor de mercado en el tiempo
- 4 Hacia mejores modelos
- 5 Frente nuevo: almacenamiento y costos AWS
- 6 Cierre

¿Qué es vectorjobs?

- Pipeline que convierte postings de LinkedIn (**123.849 jobs**, abril 2024) en un dataset *silver* reproducible.
- Recomendación job $\leftrightarrow$ skill con varios backends:
 - **TF-IDF / SVD** — baseline disperso, CPU.
 - **Qwen3-Embedding-0.6B** — denso, GPU opcional.
 - **Mock** — backend determinista para tests.
- Analítica temporal: deriva de centroides, evolución de skills, clustering interpretable y curvas de supervivencia.

Fuente de datos: Kaggle [arshkon/linkedin-job-postings](#).

Arquitectura de datos

- raw (CSV Kaggle) →
- silver (Parquet, job_card_text) →
- gold (embeddings + índices)

Hecho


- Clusters fijos ($k=12$) con centroides mensuales.
- Reportes temporales (47 figuras).
- Smoke tests semánticos.

Roadmap

- M3: extracción de skills (Qwen3-8B / vLLM).
- M4: métricas de evaluación.

Centroides: qué son y por qué importan


- Cada job es un vector (TF-IDF/SVD o denso).
- Un **centroide** es el vector promedio de un cluster (un "sector" del mercado laboral).
- Calculamos centroides **por mes** y medimos la **deriva** (distancia coseno entre meses).
- La deriva = cuánto se mueve el lenguaje/contenido de un sector en el tiempo.



Centroides en el espacio semántico



Proyección SVD 2D de los jobs, coloreada por cluster.




Trayectoria semántica de los centroides en el tiempo.

Clusters interpretables (k=12)


Cluster	#jobs
C03 data / marketing / negocio	1179
C01 job / required / company	1170
C02 proyecto / gestión / constr.	1157
C07 clientes / customer	1038
C00 care / patient / nursing	1036
C08 sales / business	818
C11 design / software / eng.	787

C03 (data/marketing) **creció** de 11 % a 37 % del share en la ventana observada.



Share de los clusters más grandes a lo largo del tiempo.

"Market cap" del mercado laboral: volumen $\times$ salario




Volumen/share: reports/temporal_clusters (10k flas, abr-2024). Salario: supuesto por sector. Caveat: limited_temporal_coverage — recalcular con jobs.parquet completo.


- Valor $\approx$ $\#$ postings $\times$ salario mediano del sector.
- Combina los dos ejes que ya medimos: **volumen** (share de clusters) y **salario**.
- Permite comparar el "tamaño económico" de cada sector y su cambio entre inicio y fin de la ventana.

Ilustrativo: salario por sector es un supuesto (cobertura real de salario = 29 %); recalcular con jobs.parquet completo. Ventana corta: limited_temporal_coverage.

El eje salarial en los datos



Cobertura de salario por mes (solo $\sim 29\%$ de las filas).



Deriva de centroides ponderada por salario (subset USD).

Nivel	Modelo	Representación	Hardware
M0–M1	TF-IDF / SVD	disperso (30–60k vocab)	CPU 6 GB
M2	Qwen3-Embedding-0.6B	denso 1536-dim	GPU T4
M3 (roadmap)	Qwen3-8B / vLLM	extracción de skills	GPU
M4 (roadmap)	—	métricas de evaluación	—

Por qué mejores modelos


- TF-IDF no capta sinónimos ni contexto.
- Embeddings densos mejoran similitud semántica y clustering.

Trade-off

- Más calidad $\Rightarrow$ más cómputo (GPU) y almacenamiento.
- Esto motiva el frente de costos.


Evolución de skills por dominio

Tech: Skill Share Evolution



Tech

Health: Skill Share Evolution




Salud

Motivación: ¿cuántos TB y a qué costo?

- Más datos + mejores modelos $\Rightarrow$ más almacenamiento y más cómputo.
- Objetivo: **estimar TB necesarios** según el crecimiento del proyecto y **proyectar el costo AWS**.
- Modelo parametrizado (`scripts/aws_cost_projection.py`):
 - ~ 12 KB/job (raw 4.3 + embedding 6 + overhead 2).
 - Base: 123.849 jobs/mes; escenarios 0 % / 5 % / 12 % MoM.

Crecimiento de almacenamiento (TB)



~12.3 KB/job (raw 4.27 + emb 6.0 + overhead 2.0); base 123,849 jobs/mes

TB acumulados a 36 meses según el ritmo de ingesta. El factor por job y la tasa de crecimiento son parámetros

Almacenamiento — S3 Standard (us-east-1)

- \$0.023/GB-mes (primeros 50 TB)
- \$0.022 (siguientes 450 TB)
- \$0.021 (>500 TB)


Cómputo — GPU EC2

- -45 % jun-2025 (p5.48xlarge \$3.86→\$2.16/h)
- +15 % ene-2026 (H200 capacity blocks)

- El precio del cómputo **no** baja de forma monótona: cambia mes a mes según oferta/demanda de GPUs.
- Conviene seguir el precio mensual y comparar antes de re-embeddear todo el corpus.

Fuentes: nops.io / cloudzero (S3 2026); cloudoptimo (recorte jun-2025); theregister / itpro (alza ene-2026).

Proyección de costo mensual (S3 + cómputo)



Conclusiones y próximos pasos

- **Centroides:** capturan y siguen la deriva de cada sector en el tiempo; base de toda la analítica temporal.
- **Valor de mercado:** volumen $\times$ salario da un proxy de "market cap" por sector — pendiente recalcular con datos completos.
- **Mejores modelos:** TF-IDF $\rightarrow$ Qwen3 $\rightarrow$ M3/M4; mejoran calidad a costa de cómputo.
- **Costos AWS:** modelo parametrizado de TB y costo con precios reales; el cómputo GPU es volátil mes a mes.

PoC de datos en la nube: `scripts/download_dataset.py` descarga el dataset de Kaggle y genera un sample pequeño reproducible.